Gestione di un dataset di film mediante orchestrazione di una pipeline

Pipeline di trasformazione dati costruita in **Azure Data Factory** per processare grandi volumi di dati cinematografici. Il progetto prevede il caricamento di un file CSV contenente informazioni su film, genere e valutazioni, e la trasformazione di tali dati per renderli più rilevanti e utilizzabili.

Passi Chiave del Processo

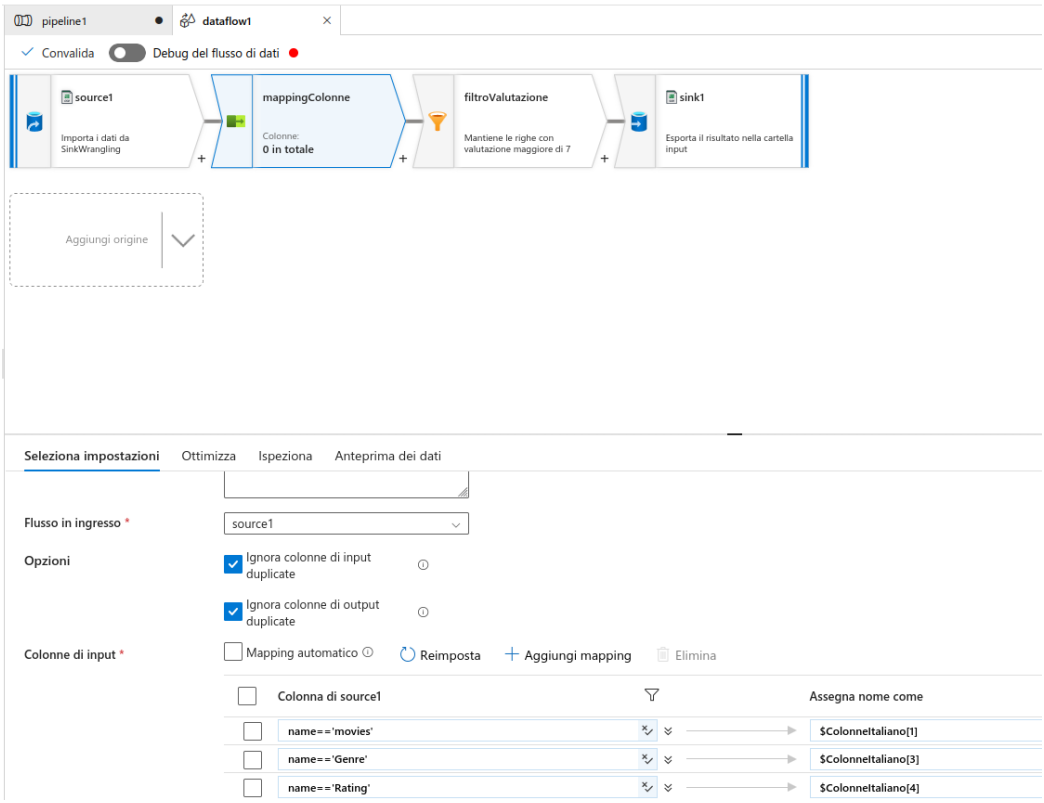
1. **Caricamento e Pulizia dei Dati**: si procede subito con la creazione di un gruppo di risorse, e successivamente con un account di archiviazione e due contenitori, **input** e **output**. Nel primo viene caricato il csv su cui effettuare le manipolazioni.
   Aprendo il csv si notano subito dei dati sporchi, ad esempio le intestazioni di colonna("YEAR" scritto in maiuscolo), oppure alcuni valori della colonna "anno" negativi. Si decide di usare power query per eseguire le operazioni di pulizia. Nello specifico:
   - si converte la colonna "YEAR" in numero, in quanto è stata riconosciuta come stringa, dopodichè si crea una colonna con il valore assoluto di YEAR per eliminare il segno negativo. Si procede poi ad eliminare la vecchia colonna
   - viene rinominata la colonna "genresgenregenre" in "Genre".
     Per quest'ultima colonna si nota inoltre che sono presenti più generi, separati dal carattere | .

   La versione di Power Query su Azure Data Factory ha delle funzioni limitate rispetto a quella presente in Excel/PowerBI, quindi non è possibile separare la colonna in base ad un carattere delimitatore, in modo da avere una colonna per ogni valore. Si decide quindi di mantenere tutti i valori in una colonna.
2. **Rimappatura dei Campi**: per la traduzione si sceglie di usare l' API della risorsa Translator, opportunamente importata nel gruppo di risorse.
   Per dare in pasto all'attività Web della traduzione le intestazioni di colonna, si sceglie di usare l'attività "recupera metadati". Dato che l'output di questa attività non contiene solo i nomi di colonna, si sceglie di estrarli tramite un costrutto **For Each**, che inserisce i valori in una lista, salvata poi come variabile.
   NB Nel For Each viene flaggata l'opzione "Sequenziale", per far sì che l'append metta le colonne nello stesso ordine in cui sono arrivate dall'attività precedente. Questo è importante per il DataFlow creato successivamente nella pipeline (vedi spiegazione al punto 3).

   Parallelamente al For Each, viene estratta, da un Vault creato appositamente per il progetto, la key necessaria per il funzionamento dell'API. Quest'operazione avviene tramite un'attività Web, con il meotodo GET.

   L'attività successiva è la traduzione vera e propria; viene quindi creata un'attività Web, con il metodo POST.

Si può quindi procedere con la mappatura in italiano: viene creato un dataflow che prende in origine il dataset salvato dopo l'elaborazione in Power Query, e si effettua una select con un mapping basato su regole. Le colonne vengono selezionate tramite il parametro **name**, la traduzione delle colonne invece è passata al dataflow tramite il parametro $ColonneItaliano, creato per permettere al dataflow di accedere alle intestazioni tradotte nella pipeline. Di seguito uno screenshot esplicativo:



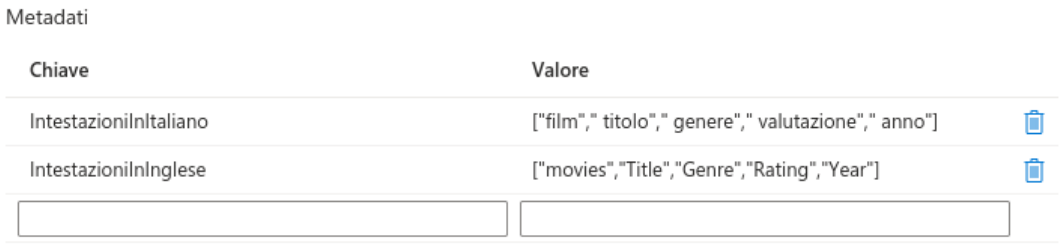
Si sfrutta in questo passaggio la possibilità di filtrare solo le colonne necessarie, quindi Film, Genere e Valutazione.

3. **Filtraggio dei Dati**: per tenere solo i record con valutazione superiore a 7, si usa un filtro nel dataflow: toInteger(byName($ColonneItaliano[4])) > 7 .
   Non è stato possibile usare direttamente il nome della colonna perché avendola assegnata nella select in modo dinamico($ColonneItaliano[4]), il generatore di espressioni non riesce a trovare le colonne inserendo direttamente il loro nome.

   A questo punto possiamo esportare il dataset pulito in un sink. Si sceglie di non esportare direttamente nel contenitore "output" perché in questa fase non si riesce a selezionare dei metadati da conservare.

4. **Trasferimento e Parallelizzazione**: l'ultima attività della pipeline è un copia dati, grazie al quale si trasferisce il dataset pulito nel contenitore di output. La parallelizzazione avviene settando il grado di parallelismo della copia nelle impostazioni dell'attività, in questo caso valorizzato a 2, data la mole non esagerata di dati che l'attività sta gestendo.

5. **Gestione dei Metadata**: nell'attività di copia dati, nelle impostazioni del sink, sono stati aggiunti due metadati: IntestazioniInItaliano e IntestazioniInInglese. Essi sono stati valorizzati con delle variabili usate precedentemente nella pipeline, e convertiti in stringa in quanto erano stati creati come matrici. È stato poi verificato nel contenitore di output che siano stati opportunamente esportati:



Documentazione

- Limiti di manipolazione di Power Query: https://learn.microsoft.com/en-us/azure/data-factory/wrangling-functions
- Ottenimento key sulla pipeline: https://learn.microsoft.com/en-us/azure/data-factory/how-to-use-azure-key-vault-secrets-pipeline-activities
- Mapping delle colonne nella select: https://learn.microsoft.com/en-us/azure/data-factory/tutorial-data-flow-dynamic-columns
- Grado di parallelismo della copia: https://learn.microsoft.com/it-it/azure/data-factory/copy-activity-performance-features#parallel-copy